优化 NIPT 时点选择与胎儿异常判定的多维分析

欧阳文迪[1], 郑轩学[1], and 任政泽[1]

[1] 香港中文大学（深圳），理工学院，数据科学学院，深圳 518172

摘要

无创产前检测（NIPT）的检出率与临床风险高度依赖”何时测、如何判”。NIPT 检测准确率由男胎的 Y 染色体浓度决定，而 Y 染色体浓度又受孕周与孕妇体征（尤以 **BMI 分层**）显著影响。对女胎而言，则需要综合染色体 Z 值、GC 含量、测序读段以及孕妇体征等指标构建异常判定方法。

针对问题 1，基于数据分布较散且并无线性强相关关系，构建非线性模型。采用 **Spearman 等级相关系数**衡量胎儿 Y 染色体浓度与孕妇 BMI、孕周数等其他指标的单调关系。在显著性检验部分，采用**置换检验**计算 p 值，进一步用 **Fisher z 变换**构造 95% 置信区间，再用 BH 方法校正多重检验。最终得到结论：孕周与 Y 染色体浓度呈显著正相关，BMI、身高、体重及年龄均与 Y 染色体浓度呈显著负相关，同时通过 BMI 分组分析发现不同 BMI 组中孕周数与 Y 染色体浓度相关的显著性存在差异。

针对问题 2，根据”早检/中间/晚检”三段不同风险提出**概率风险模型**，并用**类决策树算法**（基于**信息增益**的自学习分组递归算法）完成 BMI 分层划分，通过最优化组内风险生成各 BMI 组的最佳建议孕周 t^*。结论表明：BMI 升高则建议孕周整体后移，且该结论对风险权重和检测误差的敏感性分析保持稳健。

针对问题 3，综合考虑多种因素，以孕妇 BMI 为主要因素，年龄、身高、体重等为次要因素，采用**加权融合**策略整合单因素 BMI 划分模型与多因素**随机森林模型**：$\hat{w}_i = \lambda\,\hat{w}_i^{\mathrm{ML}} + (1-\lambda)\hat{w}_i^{\mathrm{BMI}}$。在最优权重 $\lambda \approx 0.65$ 下，融合模型成功率约 75.3%，平均风险约 1.62。

针对问题 4，对多种指标进行特征工程，围绕染色体 Z 值与 GC 含量构建比值、乘积与差分特征，采用**加权逻辑回归**、**随机森林**与 **CatBoost** 三种分类模型进行训练与对比。实验结果表明，加权逻辑回归在召回与综合判别上最优，能显著降低漏检率，推荐用于女胎异常的分类判定。

关键词: NIPT；Spearman 相关系数；BMI 分层；概率风险模型；信息增益；加权融合；CatBoost；加权逻辑回归

© Vernon Ouyang · CC BY-NC-ND 4.0 vernon.ouyang@outlook.com

目录

1 引言 **4**

2 模型假设与符号说明 **4**

2.1 模型基本假设 4

2.2 核心符号说明 5

3 胎儿 Y 染色体浓度与孕妇体征的相关分析 **5**

3.1 数据说明与预处理 5

3.2 统计方法 6

3.2.1 Spearman 等级相关系数 6

3.2.2 偏 Spearman 相关系数 7

3.2.3 置换检验 7

3.2.4 Fisher z 置信区间 7

3.2.5 BH 假发现率控制 7

3.3 结果与显著性分析 7

3.3.1 单变量 Spearman 相关与显著性检验 7

3.3.2 偏相关分析 8

3.3.3 BMI 分组显著性检验 8

3.4 结论 9

4 BMI 分组与 NIPT 最佳检测时点的自学习策略 **9**

4.1 数据说明与预处理 9

4.2 概率风险模型 9

4.3 自学习分组算法 10

4.4 实验结果 11

4.5 敏感性分析 11

4.6 结论 11

5 动态 BMI 分组、机器学习与加权融合的联合策略 **11**

5.1 背景与问题建模 11

5.2 机器学习回归模型 12

Vernon Ouyang

© Vernon Ouyang · CC BY-NC-ND 4.0 vernon.ouyang@outlook.com

5.3 加权融合策略 12
5.3.1 策略原理 12
5.3.2 最优权重确定 12
5.4 综合性能对比 12
5.5 综合多因子后的动态 BMI 分组 13
5.6 结论 13

6 女胎异常判定的建模与分析 14
6.1 数据集说明与预处理 14
6.2 特征工程 14
6.3 模型选择与算法原理 14
6.3.1 加权逻辑回归 14
6.3.2 随机森林 15
6.3.3 CatBoost 15
6.4 实验结果与分析 15
6.4.1 测试集指标对比 15
6.4.2 特征重要性分析 15
6.4.3 ROC 曲线与 PR 曲线分析 15
6.5 结论：女胎异常的综合判定方法 16

7 模型局限性与未来展望 16
7.1 问题一的局限性 16
7.2 问题二的局限性 16
7.3 问题三的局限性 16
7.4 问题四的局限性 16
7.5 进一步研究方向 17

A 附录：自学习分组算法伪代码 17

Vernon Ouyang

1 引言

无创产前检测（NIPT, Non-invasive Prenatal Test）通过采集孕妇外周血、检测胎儿来源的游离 DNA 片段，分析染色体是否存在异常，以实现对胎儿健康状况的早期筛查。在实践中需尽早发现不健康的胎儿，以降低治疗窗口期缩短的风险。

对男胎而言，NIPT 检测准确率依赖 Y 染色体浓度，而 Y 染色体浓度与孕周数和孕妇 BMI 等密切相关。如何平衡 NIPT 的检测时点及检测准确率，对检测结果可靠性至关重要。本研究针对以下四个核心科学问题展开：

问题 1： **关系刻画与检验**——分析胎儿 Y 染色体浓度与孕妇孕周数、BMI 等指标的统计特性与相互关系，给出相应的关系模型/统计检验结论，并检验其显著性。

问题 2： **基于 BMI 分组的最佳 NIPT 时点确定**——从临床角度考察”最早达到或超过 4% 的孕周”与 BMI 的关系，对男胎孕妇按 BMI 合理分组，给出各组的推荐 NIPT 时点，并分析检测误差的影响。

问题 3： **多因素情形下的 BMI 分组与 NIPT 时点建议**——在考虑身高、体重、年龄等多因素影响的前提下，结合 BMI 分组给出合理组别与推荐检测时点，并讨论检测误差对结果的影响。

问题 4： **女胎异常的判定方法**——针对 21/18/13 号染色体等异常，结合相关染色体 Z 值、GC 含量、读段数及其比例等检测统计量，构建可操作的判定规则与方法。

2 模型假设与符号说明

2.1 模型基本假设

H1. **数据有效性与独立性**：所有分析均基于清洗后的样本，已剔除关键字段缺失、异常值以及非目标人群。不同孕妇之间样本视为相互独立；同一孕妇多次检测仅用于确定”最早达标时间”，随后以个体为单位参与建模。

H2. **测序质量前置筛选**：以 GC 含量作为质量代理并限定在合理区间（35%–65%），低质量记录不进入分析，避免由测序失败导致的系统性偏差。

H3. **阈值与事件定义固定**：男胎中”达标”定义为 Y 染色体浓度首次达到或超过 4%；女胎异常标签依据 13/18/21 号染色体异常字段整理为二分类（异常 =1，正常 =0），该标注在建模期间保持不变。

H4. **关系刻画的统计假设**：不强加线性假设；相关性分析以 Spearman 相关与置换检验为主，默认单调但可非线性。多重检验采用 BH 方法控制假发现率（FDR）。

© Vernon Ouyang · CC BY-NC-ND 4.0 vernon.ouyang@outlook.com

H5. **风险与时点选择假设**：早检与晚检带来不同临床风险，采用带权的平均风险函数描述；对早/晚界限、平滑系数等使用固定超参数（并做敏感性分析），最优检测周通过网格/遍历最小化组内平均风险获得。

H6. **分组与样本量约束**：动态 BMI 分组的递归切分仅在两侧子集样本数不低于最小阈值且信息增益超过阈值时发生，防止过拟合与不稳定划分。

H7. **监督学习评估假设**：训练/测试按 8:2 随机划分；交叉验证采用分层 5 折；类别不均衡通过 `class_weight` 或显式权重处理；指标以 Accuracy/Precision/Recall/F1、ROC-AUC 与 PR-AUC 为主。

H8. **融合策略假设**：个体化预测与分组最优周之间可线性加权形成综合建议周数，权重 $\lambda \in [0,1]$ 通过先最大化成功率、并列时最小化平均风险来选取。

2.2 核心符号说明

表 1: 核心符号汇总

符号	含义
n；i	样本总数；个体索引（孕妇）
BMI_i	第 i 位孕妇的体质指数
GW	连续孕周，$GW = x + y/7$
f_Y	胎儿 Y 染色体浓度（比例）
Z_{13}, Z_{18}, Z_{21}	13/18/21 号染色体的 Z 值；GC 为对应 GC 含量
Z/GC，$Z \times GC$	由 Z 与 GC 构造的比值/乘积特征
τ_i	第 i 位孕妇首次达标孕周（$f_Y \geq 4\%$）
t；$d_i = t - \tau_i$	实际检测孕周；早/晚检差值
α, β	早检/晚检风险权重
$R_i(t)$	个体在孕周 t 的风险值
G，$\lvert G \rvert$	某 BMI 子集及其样本量
$\hat{w}_i$	融合模型预测的最优检测周数
λ	加权融合系数，$\lambda \in [0,1]$

3 胎儿 Y 染色体浓度与孕妇体征的相关分析

3.1 数据说明与预处理

原始数据共提供 1082 条男胎孕妇 NIPT 检测记录，字段包含孕妇年龄、身高、体重、检测孕周、BMI、各染色体 Z 值、X/Y 浓度、GC 含量等 31 项指标。为确保分析准确性，对原始数据进行如下处理：

© Vernon Ouyang · CC BY-NC-ND 4.0 vernon.ouyang@outlook.com

(1) **孕周解析**：将”检测孕周”字段中形如 `15w+6` 的字符串解析为连续周数变量 $t = 15 + 6/7$。

(2) **合理范围过滤**：剔除明显不合常理的体征值：年龄 $18 \le$ 年龄 ≤ 45；身高 $145\,\mathrm{cm} \le$ 身高 $\le 180\,\mathrm{cm}$；体重 $40\,\mathrm{kg} \le$ 体重 $\le 120\,\mathrm{kg}$；BMI $20 \le \mathrm{BMI} \le 50$。

(3) **测序质量筛选**：GC 含量正常范围设定为 35%–65%，删除范围外的样本。

(4) **异常样本剔除**：剔除 Y 浓度过高或过低（< 0.01 或 > 0.17）、存在染色体非整倍体异常以及”胎儿是否健康”非”是”的样本。

(5) **缺失值处理**：删除缺失孕周连续、BMI、Y 浓度等关键字段的样本。

经上述步骤清洗后，保留 906 条有效样本。表 2 汇总了主要变量的描述统计。

表 2: 清洗后数据的描述统计（$n = 906$）

变量	最小值	Q1	中位数	Q3	最大值	平均值	标准差
年龄（岁）	21.0	27.0	29.0	31.0	41.0	28.81	3.41
身高（cm）	148.0	158.0	161.0	165.0	175.0	161.22	5.04
体重（kg）	53.0	77.5	83.0	88.5	120.0	84.07	9.88
BMI	20.70	30.19	31.79	33.89	46.88	32.29	2.98
孕周 t（周）	11.0	13.29	15.86	18.29	29.0	16.66	4.01
Y 浓度	0.0100	0.0527	0.0766	0.1016	0.1676	0.0776	0.0313

Vernon Ouyang

3.2 统计方法

由于数据分布较散且无强线性相关关系，本研究采用以下方法进行分析：

3.2.1 Spearman 等级相关系数

Spearman 相关是一种非参数统计量，用于衡量两个变量之间的单调关系。对样本 $\{(x_i, y_i)\}_{i=1}^n$ 分别进行升序排列得到秩次 $r_X(i)$ 和 $r_Y(i)$，再对秩次求 Pearson 相关：

$$\rho_{XY}^S = \frac{\sum_{i=1}^n \big(r_X(i) - \bar{r}_X\big)\big(r_Y(i) - \bar{r}_Y\big)}{\sqrt{\sum_{i=1}^n \big(r_X(i) - \bar{r}_X\big)^2}\sqrt{\sum_{i=1}^n \big(r_Y(i) - \bar{r}_Y\big)^2}}. \tag{1}$$

其中 $\rho_{XY}^S \in [-1, 1]$，绝对值越大表示单调关系越强。

© Vernon Ouyang · CC BY-NC-ND 4.0 vernon.ouyang@outlook.com

3.2.2 偏 Spearman 相关系数

设包含 Y 和 k 个自变量的 Spearman 相关矩阵为 $\mathbf{R}$，其逆矩阵为 $\mathbf{P} = \mathbf{R}^{-1} = (p^{ij})$。控制其他 $k-1$ 个自变量后，Y 与某一自变量 X 的偏 Spearman 相关系数定义为：

$$\rho^{S}_{Y,X\cdot\text{others}} = -\frac{p^{12}}{\sqrt{p^{11}\,p^{22}}}. \tag{2}$$

3.2.3 置换检验

假设原假设为" 两个变量独立"，算法如下：（1）计算观测相关系数 ρ_{obs}；（2）随机打乱 y 向量，计算对应的 $\rho^{(b)}$，重复 $B = 3000$ 次；（3）统计置换样本中满足 $|\rho^{(b)}| \geq |\rho_{\text{obs}}|$ 的比例作为双侧 p 值：

$$p = \frac{1}{B}\sum_{b=1}^{B}\mathbf{1}\big(|\rho^{(b)}| \geq |\rho_{\text{obs}}|\big). \tag{3}$$

3.2.4 Fisher z 置信区间

对相关系数 ρ 进行 Fisher z 变换：

$$z = \frac{1}{2}\ln\frac{1+\rho}{1-\rho}, \qquad \text{SE}_z = \frac{1}{\sqrt{n-3}}. \tag{4}$$

95% 置信区间通过反变换得到：

$$\rho_{\text{CI}} = \tanh\big(z \pm 1.96\,\text{SE}_z\big). \tag{5}$$

3.2.5 BH 假发现率控制

同时检验多个相关系数时，采用 Benjamini–Hochberg（BH）方法控制假发现率（FDR = 0.05）。设有 m 个 p 值 $p_{(1)} \leq \cdots \leq p_{(m)}$，BH 校正后的 p 值为：

$$\tilde{p}_{(i)} = \min_{j\geq i}\frac{m}{j}p_{(j)}. \tag{6}$$

3.3 结果与显著性分析

3.3.1 单变量 Spearman 相关与显著性检验

对 Y 浓度与孕周、BMI、年龄、身高、体重计算 Spearman 相关系数，通过 3000 次置换检验获取 p 值，并经 BH 方法校正多重检验。结果如表 3 所示。

注：显著性判定基于 *BH* 校正 p 值 < 0.05。

结果表明：**孕周**与 Y 染色体浓度呈轻微正相关（$\rho = 0.082$），经置换检验和 BH 校正后仍显著；**BMI**、**身高**、**体重和年龄**均与 Y 染色体浓度呈显著负相关，其中体重的负相关最强（$\rho = -0.18$），BMI 次之。

Vernon Ouyang

© Vernon Ouyang · CC BY-NC-ND 4.0 vernon.ouyang@outlook.com

表 3: 胎儿 Y 浓度与各变量的 Spearman 相关结果

变量	相关系数 ρ	原始 p 值	置换 p 值	95% CI	BH 校正 p 值	是否显著
孕周 t	0.0823	1.32×10^{-2}	3.0×10^{-3}	$(0.0173, 0.1467)$	1.05×10^{-2}	是
BMI	-0.1522	4.20×10^{-6}	3.0×10^{-4}	$(-0.2152, -0.0879)$	1.05×10^{-5}	是
年龄	-0.0899	6.80×10^{-3}	7.7×10^{-3}	$(-0.1541, -0.0249)$	8.51×10^{-3}	是
身高	-0.1150	5.25×10^{-4}	2.3×10^{-3}	$(-0.1788, -0.0502)$	8.75×10^{-4}	是
体重	-0.1801	4.84×10^{-8}	4.0×10^{-5}	$(-0.2423, -0.1163)$	2.42×10^{-7}	是

3.3.2 偏相关分析

控制孕周后，各变量对 Y 浓度的偏 Spearman 相关系数见表 4。

表 4: 控制孕周后的偏 Spearman 相关系数

变量	偏相关 ρ	95% CI
BMI	-0.1650	$(-0.2277, -0.1010)$
年龄	-0.0894	$(-0.1536, -0.0244)$
身高	-0.1177	$(-0.1815, -0.0530)$
体重	-0.1912	$(-0.2532, -0.1276)$

控制孕周后，体重的偏相关系数达 -0.19，BMI 次之，说明在相同孕周下，体重大的孕妇其胎儿 Y 浓度更低。

3.3.3 BMI 分组显著性检验

将样本按 BMI 四分位数划分为四组，分别计算孕周与 Y 浓度的 Spearman 相关及置信区间，结果见表 5。

表 5: BMI 分组孕周与 Y 浓度的 Spearman 相关

BMI 组	样本数	BMI 范围	ρ	95% CI
Q1	227	$20.7 \sim 30.19$	-0.0356	$(-0.1650, 0.0951)$
Q2	226	$30.19 \sim 31.78$	0.1691	$(0.0395, 0.2931)$
Q3	226	$31.78 \sim 33.89$	0.0719	$(-0.0591, 0.2006)$
Q4	227	$33.89 \sim 46.88$	0.1824	$(0.0535, 0.3054)$

BMI 最低组（Q1）的相关系数接近零且置信区间覆盖零，说明低 BMI 下孕周对 Y 浓度的影响不显著；随着 BMI 增加，相关系数逐渐显著为正，表明高 BMI 孕妇需要更长孕周才能达到足够的胎儿 DNA 浓度。

Vernon Ouyang

© Vernon Ouyang · CC BY-NC-ND 4.0 vernon.ouyang@outlook.com

3.4 结论

- **孕周与胎儿 Y 浓度呈轻微正相关：**随着孕周增长，胎儿的游离 DNA 浓度略有升高，但增速有限，表明 16–20 周是 Y 浓度较稳定的阶段。
- **BMI、身高、体重及年龄均与 Y 浓度显著负相关：**尤其是体重和 BMI，提示孕妇体型越大，胎儿 DNA 被母体 DNA 稀释的效果越明显。
- **控制孕周后的净效应：**体重的偏相关系数最大（-0.19），BMI 次之，说明在相同孕周下，体重大的孕妇其胎儿 Y 浓度更低。
- **BMI 分组分析：**低 BMI 组孕周与 Y 浓度的相关性不显著；高 BMI 组孕妇孕周数对 Y 染色体浓度影响显著为正，提示检测时点宜根据 BMI 调整。

4 BMI 分组与 NIPT 最佳检测时点的自学习策略

4.1 数据说明与预处理

本节从原始数据中推导”最早达标时间”指标，具体流程如下：

(1) **分组与排序**：以”孕妇代码”为标识对数据分组，按”检测孕周”升序排序。

(2) **筛选达标记录**：提取首次出现”Y 染色体浓度 $\geq 4\%$”记录所对应的孕周作为”最早达标时间”τ_i。

(3) **数据排除规则**：若某孕妇所有检测记录中 Y 染色体浓度均未达到 4%，或仅存在 1 次检测记录，则将其排除。

通过上述方法，从原始数据中推导得到”最早达标时间”指标，整合出 254 条有效数据，使用清洗后的二列数据集 $\{(\mathrm{BMI}_i, \tau_i)\}_{i=1}^{n}$。

4.2 概率风险模型

题目材料指出早期检测（≤ 12 周）风险低，中期检测（13–27 周）风险高，晚期检测（≥ 28 周）风险极高。本研究提出一种基于概率的风险模型，定义如下变量：

表 6: 概率风险模型的关键符号与概率定义

符号	含义
$d_i = t - \tau_i$	检测周与达标周的差值：$d_i < 0$ 表示早检，$d_i > 0$ 表示晚检。
$k > 0$	逻辑函数的斜率参数，控制早/晚风险过渡的陡峭度。

© Vernon Ouyang · CC BY-NC-ND 4.0 vernon.ouyang@outlook.com

（续表）

符号	含义
δ	以周为单位的达标周容忍带；$\delta = 1$ 周时，早检定义为 $t < \tau_i - \delta$，晚检定义为 $t > \tau_i + \delta$。
$P_e(d_i) = \sigma\big(-k(d_i + \delta)\big)$	早检概率，$\sigma(x) = \frac{1}{1+\exp(-x)}$。当 t 远早于 τ_i 时 $P_e \approx 1$。
$P_l(d_i) = \sigma\big(k(d_i - \delta)\big)$	晚检概率。当 t 远晚于 τ_i 时 $P_l \approx 1$。
$P_m(d_i) = 1 - P_e(d_i) - P_l(d_i)$	中间检测概率，表示检测时点接近达标周。

设 α 和 β 分别为早检和晚检的风险权重，γ 为检测误差对早检风险的额外放大系数，ω 为中间检测风险权重。则第 i 位孕妇在检测周 t 下的风险值为：

$$R_i(t) = (\alpha + \gamma)P_e(d_i) + \beta P_l(d_i) + \omega P_m(d_i). \tag{7}$$

BMI 子集 G 在孕周 t 下的平均风险为：

$$R_G(t) = \frac{1}{|G|}\sum_{i \in G} R_i(t). \tag{8}$$

通过在候选孕周区间上寻找使 $R_G(t)$ 最小的 t，即得该 BMI 组的最佳检测孕周 t_G^*。本文取 $k = 1$、$\delta = 1$ 周、$\alpha = \beta = 1$、$\omega = 0.1$，采用网格搜索求解。

4.3 自学习分组算法

本研究设计了一个**基于信息增益的递归划分算法**，自动确定 BMI 分组边界：

(1) **计算整体风险与最佳检测周**：将所有样本视为一个组，计算平均风险 $R(t)$，找到最小风险 R^* 及最佳检测周 t^*。

(2) **尝试划分 BMI 阈值**：对每个相邻 BMI 中点 θ 将数据分成左右两部分，分别求最佳检测周与风险，计算划分后的加权风险：

$$R_{\text{split}} = \frac{|L|R_L^* + |R|R_R^*}{|G|}. \tag{9}$$

(3) **信息增益与递归**：信息增益计算为：

$$\text{Gain} = R^* - R_{\text{split}}. \tag{10}$$

若风险下降率 $(R^* - R_{\text{split}})/R^*$ 大于预设阈值（0.005）且两个子集的样本数均不少于最小样本量（30），则接受该划分并递归；否则停止，将当前组记为叶子节点。

© Vernon Ouyang · CC BY-NC-ND 4.0 vernon.ouyang@outlook.com

表 7: BMI 区间与最佳检测周数

BMI 区间	样本数	最佳检测周数	最小风险
20.71–29.03	32	12.32 周	0.66
29.02–30.46	62	12.75 周	0.67
30.46–34.32	118	12.54 周	0.66
34.32–42.38	41	13.03 周	0.74

4.4 实验结果

依据清洗处理后的男胎数据，运行上述算法得到 4 个 BMI 区间及其最佳检测周，如表 7 所示。

结果显示，**最佳检测周数随 BMI 增大而逐渐推迟**：最低 BMI 组（20.71–29.03）约在 12.32 周即可检测，最高 BMI 组（34.32–42.38）则需推迟到约 13.03 周。

4.5 敏感性分析

为评估模型对检测误差的鲁棒性，通过调整风险权重 α、β 及误差参数 γ 开展敏感性分析：

- 提高晚检惩罚（β）会促使最优时点略提前；
- 提高检测误差权重（γ）会促使时点顺延；
- 对分组数量影响有限，”BMI 升高则建议孕周后移” 的单调规律保持稳健。

4.6 结论

基于概率风险模型与自学习分组算法，本研究得到清晰的一致规律：BMI 升高则建议 NIPT 检测孕周整体后移。算法可自动发现最优 BMI 分组边界，结论对风险权重和检测误差参数的扰动具有较强的鲁棒性。

5 动态 BMI 分组、机器学习与加权融合的联合策略

5.1 背景与问题建模

本节在第 3 节基础上，综合考虑孕妇 BMI、年龄、身高、体重等多种因素，给出更精细的 BMI 分组与最佳 NIPT 检测时点建议。研究策略如下：

1. **单因素 BMI 划分模型**：即第 3 节结果，成功率约 66.7%；

Vernon Ouyang

© Vernon Ouyang · CC BY-NC-ND 4.0 vernon.ouyang@outlook.com

2. **多因素机器学习回归模型**：对”最早合格时间”做监督回归，可提升至 58.8%–74%，但存在偏早/偏晚风险；
3. **加权融合**：将两者线性融合以兼顾成功率与风险。

数据处理同第 3 节，保留年龄、身高、体重、BMI、Y 浓度、18 号染色体 Z 值、怀孕次数等变量，共 254 条样本。

5.2 机器学习回归模型

采用两类代表性模型对”最早合格时间”做回归建模：

- **随机森林（RF）**：基学习器数 200，最大深度 42；5 折交叉验证 MAE ≈ 1.88 周，RMSE ≈ 2.75 周；
- **梯度提升（GB）**：基学习器数 300，学习率 0.05，最大深度 3；MAE ≈ 1.95 周，RMSE ≈ 2.75 周。

总体上随机森林略优，预测输出截断到 $[10, 20]$ 的整数周。

5.3 加权融合策略

5.3.1 策略原理

线性加权融合公式为：

$$\hat{w}_i = \lambda\, \hat{w}_i^{\mathrm{ML}} + (1-\lambda)\, \hat{w}_i^{\mathrm{BMI}}, \qquad \lambda \in [0,1]. \tag{11}$$

对 $\lambda \in \{0, 0.05, \ldots, 1.0\}$ 逐一评估成功率与平均风险，先最大化成功率，再在并列解中最小化平均风险。

5.3.2 最优权重确定

实验结果显示：成功率在 $\lambda \approx 0.6$ 附近跃升并保持高位；平均风险随 λ 增大缓慢抬升。综合权衡，$\lambda \approx 0.65$ 为推荐取值，对应成功率约 75.3%，平均风险约 1.62。

5.4 综合性能对比

对测试集分别应用四种策略，综合性能对比见表 8。

融合策略在成功率上领先（75.3%），且风险低于纯随机森林（1.62 vs. 1.72），总体权衡最优。

© Vernon Ouyang · CC BY-NC-ND 4.0 vernon.ouyang@outlook.com

表 8: 不同策略的综合性能对比

策略	成功率	平均检测周数	平均风险
BMI 单因素	0.610	13.27	1.50
随机森林	0.740	13.77	1.72
梯度提升	0.649	13.57	1.91
融合策略（$\lambda = 0.65$）	**0.753**	13.68	1.62

5.5 综合多因子后的动态 BMI 分组

以加权融合模型预测每位孕妇的最早合格时间 $\hat{\tau}_i$，用 $\hat{d}_i = t - \hat{\tau}_i$ 替代 d_i 构建个体风险：

$$\hat{R}_i(t) = (\alpha + \gamma)P_e(\hat{d}_i) + \beta P_l(\hat{d}_i) + \omega P_m(\hat{d}_i). \tag{12}$$

延续第 3 节的递归分割算法，在训练集上以预测值指导 BMI 的切分，最终得到 4 个 BMI 区间与对应的最优检测周数，见表 9。

表 9: 多因子驱动的动态 BMI 分组及其最优检测周

组编号	BMI 区间	样本数	最优检测周数
M0	20.70–29.09	26	13.4 周
M1	29.12–33.14	107	12.9 周
M2	33.21–35.16	23	13.4 周
M3	35.29–45.71	21	16.2 周

相较于单因素 BMI 划分，多因子方案对高 BMI 人群进行了进一步细分，**最优检测周随 BMI 提升而整体后移**，该规律与第 3 节结论高度一致。在测试集上，该方案取得成功率约 66.2%、平均检测周 13.35 周、平均风险 1.41。

5.6 结论

加权融合模型在成功率（75.3%）与风险（1.62）之间实现了最优平衡，优于任何单一策略。综合多因子 BMI 分组进一步细化了高 BMI 人群的分层，兼顾了 BMI 作为主导因素的可解释性与多维个体差异的预测精度。

Vernon Ouyang

© Vernon Ouyang · CC BY-NC-ND 4.0 vernon.ouyang@outlook.com

6 女胎异常判定的建模与分析

6.1 数据集说明与预处理

女胎检测数据共 300 条，包括 12 个特征字段及二分类标签（异常 =1，正常 =0）。由于女胎无 Y 染色体，需依靠 13/18/21 号染色体 Z 值、GC 含量、读段数及孕妇体征等构建分类模型。

数据预处理步骤如下：（1）孕周解析，同第 2 节；（2）类别标签整理，将 13/18/21 号染色体非整倍体标识合并为二值异常标签；（3）删除关键字段缺失的记录；（4）异常值过滤（Z 值、GC 含量等）。最终保留 288 条有效样本，其中正常样本 258 条、异常样本 30 条，存在显著的类别不均衡。

6.2 特征工程

首先对原始指标进行皮尔逊相关系数分析，然后围绕 Z 值与 GC 含量构造如下衍生特征，以缓解 GC 偏倚并强化相对差异：

- **比值特征**：Z_{13}/GC_{13}、Z_{18}/GC_{18}、Z_{21}/GC_{21}；
- **乘积特征**：$Z_{13} \times GC_{13}$、$Z_{18} \times GC_{18}$、$Z_{21} \times GC_{21}$；
- **差分特征**：$Z_{21} - Z_{18}$、$Z_{21} - Z_{13}$、$Z_{18} - Z_{13}$。

6.3 模型选择与算法原理

本研究对比三种主流分类模型：

6.3.1 加权逻辑回归

设特征向量为 $\mathbf{x}_i \in \mathbb{R}^p$，目标为 $y_i \in \{0, 1\}$。加权逻辑回归通过设置正类权重 $w_1 > 1$ 缓解类别不均衡：

$$\hat{y}_i = \sigma(\mathbf{w}^\top \mathbf{x}_i + b) = \frac{1}{1 + \exp(-(\mathbf{w}^\top \mathbf{x}_i + b))}. \tag{13}$$

加权交叉熵损失为：

$$\mathcal{L} = -\frac{1}{n} \sum_{i=1}^{n} \big[w_{y_i}\, y_i \log \hat{y}_i + w_{y_i} (1 - y_i) \log(1 - \hat{y}_i) \big]. \tag{14}$$

本研究取正类权重 $w_1 = 8$。

© Vernon Ouyang · CC BY-NC-ND 4.0 vernon.ouyang@outlook.com

6.3.2 随机森林

随机森林通过构造 T 棵独立的决策树（每棵树在 Bootstrap 样本上训练）并投票融合：

$$\hat{y} = \mathrm{argmax}_c \frac{1}{T} \sum_{t=1}^{T} \mathbf{1}\big(\hat{y}^{(t)} = c\big). \tag{15}$$

通过 `class_weight="balanced"` 处理类别不均衡。

6.3.3 CatBoost

CatBoost 是一种梯度提升树算法，使用有序提升（Ordered Boosting）策略减少预测偏移：

$$F_m(\mathbf{x}) = F_{m-1}(\mathbf{x}) + \eta\, h_m(\mathbf{x}), \tag{16}$$

其中 h_m 为最小化损失函数负梯度的弱学习器。本研究取迭代次数 500、学习率 0.05，通过 `scale_pos_weight` 处理类别不均衡。

6.4 实验结果与分析

6.4.1 测试集指标对比

三种模型在测试集上的性能指标见表 10。

表 10: 三种模型在测试集上的分类性能对比

模型	准确率	精确率	召回率	F1	ROC_AUC	PR_AUC
加权逻辑回归	**0.897**	0.615	**0.889**	**0.727**	**0.955**	**0.726**
随机森林	0.897	**0.800**	0.444	0.571	0.896	0.617
CatBoost	0.879	0.667	0.444	0.533	0.880	0.570

6.4.2 特征重要性分析

特征重要性分析显示，Z_{21}、Z_{18} 及其差分特征（$Z_{21} - Z_{18}$、$Z_{21} - Z_{13}$）为最主要贡献因子；BMI、X 染色体浓度与 GC 相关构造特征提供有效补充；Z_{13} 单独的贡献相对较小。

6.4.3 ROC 曲线与 PR 曲线分析

加权逻辑回归的 ROC-AUC 达 0.955，远高于随机森林（0.896）和 CatBoost（0.880），在各召回水平下的精确率也最优，表明其在小样本与类不均衡场景下具有更强的综合判别能力。

Vernon Ouyang

6.5 结论：女胎异常的综合判定方法

综合上述分析，本研究建议以**加权逻辑回归模型**对女胎异常做分类判定，理由如下：

- **召回率最高**（0.889）：在医学筛查场景下，漏检（假阴性）的代价远高于误检，高召回率能显著降低漏检风险；
- **综合判别最优**：ROC-AUC（0.955）与 F1 分数（0.727）均优于其他两种模型；
- **可解释性强**：逻辑回归提供特征系数，便于临床医生理解判定依据；
- **适用于小样本不均衡场景**：通过调整正类权重处理类别不均衡，无需大规模数据支撑。

判定依据的核心特征为：Z_{21}、Z_{18} 及其差分（$Z_{21}-Z_{18}$、$Z_{21}-Z_{13}$），辅以 BMI、X 染色体浓度与 GC 比值/乘积等构造特征。

7 模型局限性与未来展望

7.1 问题一的局限性

本模型通过 Spearman 相关系数与偏相关分析揭示了孕妇 BMI、孕周等变量对 Y 染色体浓度的影响，但依赖传统相关分析方法，未能完全捕捉数据中的非线性关系和复杂交互作用。未来可引入机器学习算法（如随机森林或神经网络）进一步挖掘特征间的复杂非线性关系。

7.2 问题二的局限性

基于信息增益的递归分割算法对固定 BMI 分组范围存在依赖，未考虑不同群体间的个体差异。未来可引入自适应分组方法，结合强化学习以适应实际情况的变化。

7.3 问题三的局限性

多因素融合模型仍未考虑孕妇其他未被测量的生理特征及外部环境因素。未来可在模型中加入基因数据、生活习惯等更多变量，以提高模型的全面性和精确性。

7.4 问题四的局限性

当前方法对复杂图谱结构的刻画能力有限；随着数据规模扩大，现有方法在计算资源与效率上亦可能受限。未来可将图谱特征与更丰富的深度模型（如 GCN/GAT）结合，并探索过采样/焦点损失、半监督/迁移学习等策略，以更好地捕捉非线性与高阶交互。

Vernon Ouyang

© Vernon Ouyang · CC BY-NC-ND 4.0 vernon.ouyang@outlook.com

7.5 进一步研究方向

- **数据多样性与完整性**：随着数据量增加，如何处理大规模、多维度数据将成为关键，数据增强和半监督学习可能提升模型在数据稀缺情况下的表现；
- **模型泛化能力**：加强对不同地区或群体的泛化能力验证；
- **实时预测与更新**：结合实时数据流，形成自我学习和自我优化的动态决策系统，提升模型的长期有效性。

参考文献

[1] Benjamini, Y., & Hochberg, Y. (1995). Controlling the false discovery rate: a practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society: Series B (Methodological)*, 57(1), 289–300. https://doi.org/10.1111/j.2517-6161.1995.tb02031.x

[2] Puth, M. T., Neuhauser, M., & Ruxton, G. D. (2015). Effective use of Spearman's and Kendall's correlation coefficients for association between two measured traits. *Animal Behaviour*, 102, 77–84. https://doi.org/10.1016/j.anbehav.2015.01.010

[3] Scott, F. P., Menezes, M., Palma-Dias, R., Nisbet, D., Schluter, P., da Silva Costa, F., et al. (2017). Factors affecting cell-free DNA fetal fraction and the consequences for test accuracy. *The Journal of Maternal-Fetal & Neonatal Medicine*, 31, 1865–1872. https://doi.org/10.1080/14767058.2017.1330881

[4] Wang, E., Batey, A., Struble, C., Musci, T., Song, K., & Oliphant, A. (2013). Gestational age and maternal weight effects on fetal cell-free DNA in maternal plasma. *Prenatal Diagnosis*, 33, 662–666. https://doi.org/10.1002/pd.4119

[5] Zhou, Y., Zhu, Z., Gao, Y., Yuan, Y., Guo, Y., Zhou, L., et al. (2015). Effects of maternal and fetal characteristics on cell-free fetal DNA fraction in maternal plasma. *Reproductive Sciences*, 22, 1429–1435. https://doi.org/10.1177/1933719115584445

A 附录：自学习分组算法伪代码

Vernon Ouyang

Algorithm 1 基于信息增益的 BMI 递归分组算法

Require: 数据集 $\mathcal{D} = \{(\mathrm{BMI}_i, \tau_i)\}$，最小样本量 $n_{\min}$，增益阈值 ϵ

Ensure: BMI 分组边界集合 $\mathcal{B}$，各组最优检测周 $\{t_G^*\}$

函数 SPLIT(G):
  计算 R_G^*，t_G^* 通过最小化 $R_G(t)$
if $|G| < 2n_{\min}$ **then**
    返回 $\{(G, t_G^*)\}$
end if
将 G 中样本按 BMI 升序排列
best_gain $\leftarrow 0$，best_split $\leftarrow$ None
for 每个相邻 BMI 中点 θ **do**
  划分 G 为 $L = \{i \in G : \mathrm{BMI}_i \leq \theta\}$ 和 $R = G \setminus L$
  if $|L| \geq n_{\min}$ **and** $|R| \geq n_{\min}$ **then**
    计算 R_L^*，R_R^*
    $R_{\text{split}} \leftarrow (|L|R_L^* + |R|R_R^*)/|G|$
    gain $\leftarrow (R_G^* - R_{\text{split}})/R_G^*$
    if gain $>$ best_gain **then**
      best_gain $\leftarrow$ gain，best_split $\leftarrow (L, R)$
    end if
  end if
end for
if best_gain $> \epsilon$ **then**
  返回 SPLIT(L) $\cup$ SPLIT(R)
else
  返回 $\{(G, t_G^*)\}$
end if
输出： SPLIT($\mathcal{D}$)

Vernon Ouyang

© Vernon Ouyang · CC BY-NC-ND 4.0 vernon.ouyang@outlook.com